


UNIVERSIDADE FEDERAL DO PARÁ
INSTITUTO DE CIÊNCIAS EXATAS E NATURAIS
PROGRAMA DE PÓS-GRADUAÇÃO EM ENSINO DE COMPUTAÇÃO
PARA A EDUCAÇÃO BÁSICA (PROFCOMP)

# Ensino introdutório de *machine learning* no Ensino Médio por meio de uma sequência didática apoiada por uma plataforma interativa

Luiz Gabriel Bezerra da Conceição

Belém–PA
2026

UNIVERSIDADE FEDERAL DO PARÁ
INSTITUTO DE CIÊNCIAS EXATAS E NATURAIS
PROGRAMA DE PÓS-GRADUAÇÃO EM ENSINO DE COMPUTAÇÃO
PARA A EDUCAÇÃO BÁSICA (PROFCOMP)

Luiz Gabriel Bezerra da Conceição

# Ensino introdutório de *machine learning* no Ensino Médio por meio de uma sequência didática apoiada por uma plataforma interativa

Projeto de qualificação apresentado ao Programa de Pós-Graduação em Ensino de Computação para a Educação Básica da Universidade Federal do Pará, como requisito parcial para a qualificação no curso de Mestrado Profissional em Ensino de Computação.

Orientador: Prof. Dr. Marcus de Barros Braga

Belém–PA
2026

# Resumo

O avanço de aplicações baseadas em inteligência artificial tornou comum que estudantes da Educação Básica convivam com sistemas inteligentes, sem que isso assegure a compreensão dos dados, regras e escolhas subjacentes ao seu funcionamento. Este projeto de qualificação investiga o ensino introdutório de *machine learning* no Ensino Médio, concebido como conteúdo de Computação voltado a explicitar como modelos computacionais utilizam dados para produzir previsões, classificações e agrupamentos. O estudo tem como objetivo geral desenvolver e analisar uma sequência didática apoiada por uma plataforma interativa para o ensino de fundamentos de *machine learning* a estudantes do Ensino Médio. A proposta pedagógica fundamenta-se nas normas curriculares da Resolução CNE/CEB nº 1/2022, no pensamento computacional e no aporte de múltiplas representações, estruturando-se no ciclo didático prever, experimentar, observar e explicar. O produto educacional articula uma sequência didática de oito encontros a uma plataforma web interativa executada localmente com dados sintéticos tabulares, contemplando cinco modelos introdutórios: regressão linear, regressão logística, $k$-vizinhos mais próximos ($k$-NN), árvore de decisão e $k$-means. Metodologicamente, a pesquisa é de natureza aplicada, com abordagem predominantemente qualitativa e apoio de dados quantitativos descritivos, configurando-se como intervenção pedagógica realizada em uma turma de Ensino Médio sob docência do pesquisador. A produção de dados baseia-se em um diagnóstico inicial individual, registros docentes breves após cada aula e um desafio final individual de síntese com situações-problema inéditas. A análise qualitativa das produções examinará indícios de compreensão em quatro dimensões conceituais: reconhecimento de dados e finalidade da tarefa; antecipação de consequências de alterações; interpretação de representações; e discussão de limites de decisões automatizadas, subsidiando a sistematização do produto educacional e de parâmetros reflexivos para a atuação docente na escola pública.

**Palavras-chave**: Ensino de Computação; Machine Learning; Ensino Médio; Sequência Didática; Plataforma Interativa; Produto Educacional.

# Lista de tabelas

Tabela 1 – Etapas e atividades do cronograma provisório da pesquisa . . . . . 28

# Lista de abreviaturas e siglas

| | |
|---|---|
| BNCC | Base Nacional Comum Curricular |
| CEB | Câmara de Educação Básica |
| CNE | Conselho Nacional de Educação |
| CNS | Conselho Nacional de Saúde |
| IA | Inteligência Artificial |
| k-NN | *k*-Nearest Neighbors (*k*-Vizinhos Mais Próximos) |
| MEC | Ministério da Educação |
| ML | *Machine Learning* (Aprendizado de Máquina) |
| PPA | Projeto Permanente por Afinidade |
| PROFCOMP | Programa de Pós-Graduação em Ensino de Computação para a Educação Básica |
| SBC | Sociedade Brasileira de Computação |
| UFPA | Universidade Federal do Pará |

# Sumário


**1 Introdução . . . . . 1**
1.1 Contextualização e delimitação do tema . . . . . 1
1.2 Problema educacional e justificativa . . . . . 2
1.3 Pergunta de pesquisa . . . . . 4
**2 Objetivos . . . . . 5**
2.1 Objetivo geral . . . . . 5
2.2 Objetivos específicos . . . . . 5
**3 Referencial Teórico . . . . . 6**
3.1 Ensino de Computação, inteligência artificial e formação na Educação Básica . 6
3.2 *Machine learning* introdutório no Ensino Médio . . . . . 7
3.3 Representações, visualização e experimentação guiada . . . . . 10
3.4 Avaliação da compreensão durante a intervenção . . . . . 12
3.5 Síntese do referencial e posicionamento da proposta . . . . . 13
**4 Produto Educacional e Sequência Didática . . . . . 15**
4.1 Concepção do produto educacional . . . . . 15
4.2 Organização pedagógica da plataforma . . . . . 16
4.3 Cenários e dados dos experimentos . . . . . 16
4.4 Sequência didática provisória . . . . . 17
4.5 Materiais e limites do produto . . . . . 19
4.6 Alinhamento curricular preliminar . . . . . 19
**5 Percurso Metodológico . . . . . 21**
5.1 Natureza, abordagem e estratégia da pesquisa . . . . . 21
5.2 Contexto e participantes . . . . . 21
5.3 Etapas da intervenção . . . . . 22
5.4 Instrumentos de produção de dados . . . . . 23
5.5 Procedimentos de análise . . . . . 24
5.6 Aspectos éticos . . . . . 25
**6 Contribuições Esperadas e Limites da Proposta . . . . . 26**
6.1 Contribuições esperadas . . . . . 26
6.2 Limites e riscos reconhecidos . . . . . 27
**7 Cronograma Provisório . . . . . 28**

**Referências . . . . . 29**

# 1 Introdução

## 1.1 Contextualização e delimitação do tema

A incorporação de recursos de inteligência artificial às rotinas escolares e sociais dos estudantes aproxima os jovens de respostas prontas que dispensam o esforço cognitivo. Esse movimento se intensifica nas redes sociais e em plataformas de vídeo, onde circulam demonstrações de ferramentas que realizam atividades acadêmicas e prometem resultados rápidos.

Assistir a essas demonstrações, porém, não garante que o estudante aprenda o conteúdo nem que compreenda como a inteligência artificial opera, quais dados utilizou e por qual processo chegou ao resultado. Sem esse entendimento, o estudante recebe a saída sem desenvolver análise crítica sobre ela, e o currículo escolar tem pouco espaço para explicar como uma inteligência artificial chega às suas respostas. A Resolução CNE/CEB nº 1/2022 define diretrizes para a Computação na Educação Básica como complemento à Base Nacional Comum Curricular e atribui aos sistemas de ensino a organização da implantação curricular (BRASIL, 2022). Em 2026, o Ministério da Educação publicou o documento orientador *Inteligência artificial na Educação Básica*, que reforça o papel do professor e defende que a IA seja tratada como recurso de tutoria e apoio à aprendizagem, e não apenas como geradora de respostas prontas (BRASIL, 2026).

A educação em inteligência artificial tem sido debatida internacionalmente como parte da formação cidadã, pois os estudantes precisam compreender, conforme sua escolaridade, as possibilidades e os limites de sistemas inteligentes (TOURETZKY et al., 2019). No Ensino Médio, essa necessidade se coloca de modo particular: usar muito os recursos digitais não é o mesmo que ter letramento computacional. Muitos estudantes usam celulares e aplicativos com desenvoltura, mas nem sempre tiveram oportunidade de interpretar com autonomia uma tabela, distinguir correlação de previsão ou perceber por que um resultado muda quando a regra é alterada. Outros ainda enfrentam restrições de acesso a computador e internet fora da escola.

A discussão sobre o uso responsável deve ser acompanhada pelo ensino dos conceitos que explicam como a inteligência artificial gera suas respostas. Se a conversa se limita a liberar ou proibir uma ferramenta, o estudante continua sendo apenas usuário, e entender como uma inteligência artificial é treinada pode ampliar sua consciência sobre o que ela é e favorecer um uso voltado ao seu próprio desenvolvimento cognitivo. O ensino de Computação permite deslocar a conversa para o que alimenta um modelo e por que uma mudança nos dados altera sua resposta, e este projeto focaliza o ensino introdutório de *machine learning* para discuti-lo a partir da relação entre dados e modelos computacionais.

O recorte não pretende exigir programação prévia nem formar especialistas em algorit-

mos. Em oito encontros, estudantes do Ensino Médio observarão dados, formularão hipóteses e explicarão o efeito de modificar parâmetros, com a Matemática como linguagem de interpretação, e não como barreira inicial para o estudo do problema.

## 1.2 Problema educacional e justificativa

Na rotina escolar, alguns estudantes recorrem à inteligência artificial para obter resultados imediatos, sem necessariamente se apropriar do conhecimento envolvido. Quando esse uso se limita à obtenção de respostas prontas, o estudante não necessariamente compreende como a ferramenta funciona. Nesse caso, o ensino dos conceitos básicos de *machine learning* pode ajudá-lo a conhecer o processo por trás das respostas que recebe. Mas aí surge um segundo problema, que é o pouco contato dos estudantes com dados.

Em geral, tabelas e gráficos apresentados no Ensino Médio chegam prontos, inseridos em questões. O estudante lê o que está na página, mas não pergunta de onde vieram os dados nem reflete sobre o que mudaria no resultado se um valor ou uma condição fosse diferente.

Essa lacuna é relevante porque compreender um modelo de *machine learning* exige algum contato prévio com dados, além de noções básicas de estatística e probabilidade. Já existem trabalhos voltados ao ensino do tema na Educação Básica. Em um mapeamento de 30 unidades didáticas, Marques, Gresse von Wangenheim e Hauck (2020) observaram que várias delas cobrem apenas os processos mais acessíveis, como a gestão de dados, ou apresentam o aprendizado e o teste dos modelos de forma abstrata, deixando parte do funcionamento interno oculto. Isso sugere que, nessas unidades, o contato com dados pode se restringir à gestão, sem mostrar como os dados e os parâmetros alteram o resultado do modelo. No Ensino Médio, a revisão de Martins e Gresse von Wangenheim (2023) indica que os estudantes conseguem compreender e aplicar conceitos, algoritmos e tarefas básicas de *machine learning*. A mesma revisão aponta a necessidade de avaliações mais rigorosas sobre como o tema é ensinado. A presença da inteligência artificial na escola também exige situações em que os estudantes relacionem os dados à finalidade da tarefa, à regra, ao parâmetro e ao resultado do modelo.

Quando os dados chegam prontos e as relações entre eles não são trabalhadas, o estudante tende a aprender os conceitos de *machine learning* apenas pelo nome. Termos como treinamento, modelo, parâmetro e previsão podem ser repetidos sem que se saiba como se ligam entre si. Um estudante pode dizer que um modelo foi treinado sem saber explicar o que muda quando um parâmetro é alterado, e pode reconhecer uma reta no gráfico sem relacioná-la a uma previsão. O problema educacional está na passagem entre nomear um conceito e utilizá-lo para explicar uma situação.

Há ainda uma diferença importante entre apresentar a inteligência artificial como tema de cultura digital e ensiná-la como conteúdo de Computação. A discussão cultural é indispensável para tratar de riscos, vieses, autoria e impactos sociais. No ensino de Computação, o estudante

também precisa investigar, na prática, uma representação de dados e uma regra computacional. A proposta não reduz questões éticas a uma equação ou a um gráfico. Considera-se que a discussão sobre limites passa a ter outra base quando o estudante reconhece que modelos resultam de decisões humanas de modelagem.

Romper com a recepção passiva de resultados prontos exige oportunidades para prever, alterar dados ou parâmetros, observar o efeito produzido e explicar por que ele surgiu. Esse processo começa antes do modelo, na origem dos dados. Um estudante que monta uma tabela com medidas da própria turma sabe de onde vêm os números e o que cada coluna representa. Essa experiência torna a leitura do gráfico menos mecânica. Em seguida, ver uma reta se deslocar quando os dados mudam, ou a mudança de categoria quando o limiar é alterado, produz evidências visíveis. Ao explicar o que observou, o estudante pode relacionar o efeito visual à alteração que realizou. Essa organização se aproxima das abordagens práticas, baseadas em problemas ou projetos, que Martins e Gresse von Wangenheim (2023) identificaram como bem-sucedidas no Ensino Médio. Compreender de onde vêm os dados e o que muda com um parâmetro é o que permite ao estudante questionar o resultado que recebe, e não apenas aceitá-lo.

O produto educacional prevê uma plataforma interativa em português brasileiro, articulada a uma sequência didática para estudantes do Ensino Médio. A plataforma apresenta cinco módulos introdutórios: regressão linear, regressão logística, $k$-vizinhos mais próximos, árvore de decisão e $k$-means. Os modelos serão tratados como conteúdos centrais, sem receber necessariamente a mesma formalização matemática. A regressão linear permite explorar tendência, previsão e erro; a regressão logística introduz probabilidade e limiar. O $k$-NN coloca em evidência distância e votação; a árvore de decisão trabalha com regras e divisões; o $k$-means permite discutir grupos e dados sem rótulos prévios.

O uso da plataforma, por si só, não será tomado como evidência de aprendizagem. Ferramentas visuais podem apoiar a compreensão, mas seu potencial depende de como as representações são desenhadas e das tarefas cognitivas pedidas aos estudantes (AINSWORTH, 2006). Por isso, cada módulo relacionará uma situação-problema, a origem dos dados, uma hipótese inicial, uma manipulação controlada e uma explicação posterior. A sequência segue o movimento de prever, experimentar, observar e explicar. A devolutiva do experimento participa da mediação docente, aproximando-se da avaliação formativa discutida por Black e Wiliam (1998). Serão oito encontros de cerca de 50 minutos, com dados coletados pela própria turma nos encontros 2 e 8 e fornecidos pelo site, em cenários sintéticos, nos encontros 3 a 7. Um estudante que modifica o limiar de uma classificação precisa discutir por que a mudança ocorreu. Sem essa conversa, o controle vira um botão sem significado.

A justificativa profissional está na necessidade de um recurso que possa ser aplicado e analisado por um professor da Educação Básica, em turmas heterogêneas, com tempo limitado e infraestrutura que varia entre escolas. Para um programa profissional como o ProfComp, a articulação entre problema escolar, conteúdo de Computação, intervenção docente e produto utilizável

é parte central da relevância do estudo. A plataforma não será avaliada como software genérico, nem a pesquisa pretende demonstrar que qualquer interface interativa resolve dificuldades de aprendizagem.

Espera-se contribuir para uma discussão que não trate a inteligência artificial como conteúdo reservado a cursos técnicos, nem a simplifique a ponto de ocultar como um modelo funciona. A contribuição é localizada e dependerá das condições de aplicação. Documentar essas condições pode ajudar outros docentes a avaliar se uma proposta semelhante serve ao seu contexto, sem antecipar generalizações que a pesquisa não poderá sustentar.

## 1.3 Pergunta de pesquisa

Como estudantes do Ensino Médio demonstram compreensão de fundamentos introdutórios de *machine learning* ao participar de uma sequência didática, apoiada por uma plataforma interativa, que aborda cinco modelos?

A pergunta olha para o modo como essa compreensão aparece nas explicações, nas interpretações de gráficos e tabelas e nas escolhas justificadas pelos estudantes. Não se pretende responder se a plataforma, isoladamente, funciona nem calcular um ganho geral de aprendizagem. O interesse está em examinar como os estudantes articulam os componentes de um modelo computacional, se questionam a origem dos dados e como explicam os efeitos de alterá-los. Essas relações serão observadas em produções individuais, elaboradas em um percurso mediado pelo professor e influenciado pelo contexto da turma.

# 2 Objetivos

## 2.1 Objetivo geral

Desenvolver e analisar uma sequência didática apoiada por uma plataforma interativa para o ensino introdutório de fundamentos de *machine learning*, como conteúdo de Computação, a estudantes do Ensino Médio.

## 2.2 Objetivos específicos

Os objetivos específicos desta pesquisa compreendem:

- analisar referências sobre ensino de inteligência artificial e *machine learning* na Educação Básica, visualização interativa, múltiplas representações e avaliação da compreensão conceitual;
- relacionar os objetivos de aprendizagem da sequência aos eixos e às habilidades pertinentes da Computação na Educação Básica, sem supor que a norma prescreva algoritmos específicos;
- organizar uma sequência didática que trabalhe regressão linear, regressão logística, *k*-vizinhos mais próximos, árvore de decisão e *k*-means por meio do ciclo prever, experimentar, observar e explicar;
- ajustar cenários sintéticos, atividades de organização de tabelas pela turma, controles e explicações matemáticas da plataforma às condições do campo de aplicação;
- aplicar a sequência em uma turma de Ensino Médio em que o pesquisador é o professor;
- analisar, nas explicações, interpretações de gráficos e tabelas e escolhas justificadas dos estudantes, indícios de compreensão sobre origem dos dados, finalidade da tarefa, regra, parâmetro e resultado, presentes no diagnóstico inicial, no desafio final individual e nos registros docentes breves;
- sistematizar a plataforma, a sequência e os instrumentos de aplicação como produto educacional.

# 3 Referencial Teórico

## 3.1 Ensino de Computação, inteligência artificial e formação na Educação Básica

O ensino de Computação na Educação Básica não se limita ao uso de ferramentas digitais. Ele envolve conhecimentos e práticas que permitem compreender o funcionamento de sistemas computacionais. Recursos cotidianos baseados em inteligência artificial aproximam essa discussão da experiência dos estudantes, mas essa proximidade não substitui o ensino dos princípios que orientam esses recursos.

A Resolução CNE/CEB nº 1/2022 estabelece normas para a Computação como complemento à BNCC e atribui aos sistemas de ensino a definição de parâmetros e abordagens para sua implementação (BRASIL, 2022).

O ensino de Computação difere da informática na educação, em que o computador apoia a aprendizagem de conteúdos de diversas áreas e o foco recai sobre sua inserção pedagógica (VALENTE, 2002). A plataforma deste projeto também será um recurso didático, mas o objeto central de aprendizagem não é operar a interface nem estudar um conteúdo externo com auxílio do computador.

A proposta focaliza conceitos e práticas da Computação relacionados ao funcionamento e aos limites de sistemas de inteligência artificial. Espera-se que os estudantes interpretem como dados e regras participam da produção de uma saída, comparem finalidades de diferentes modelos, antecipem efeitos de modificações e expliquem os resultados observados.

A Matemática apoia essa leitura por meio de gráficos, funções, distância, probabilidade, média e erro, sem substituir o conteúdo computacional que organiza as atividades. A Computação na Educação Básica se estrutura pelos eixos Pensamento Computacional, Mundo Digital e Cultura Digital, para os quais as Diretrizes da Sociedade Brasileira de Computação e a Resolução CNE/CEB nº 1/2022 oferecem referências (SOCIEDADE BRASILEIRA DE COMPUTAÇÃO, 2018; BRASIL, 2022). Os eixos não serão tratados como conteúdos separados, mas evitam que a plataforma se reduza a controles técnicos. No Ensino Médio, as habilidades da norma ligadas à inteligência artificial, aos modelos computacionais e à análise de dados orientam a seleção dos conteúdos (BRASIL, 2022).

O pensamento computacional participa da proposta como forma de organizar e analisar problemas, dados e regras, e não como sinônimo de qualquer atividade realizada com computador. Wing (2006) chama a atenção para práticas como abstração e decomposição na formulação de soluções computacionais. Neste estudo, essa aproximação aparece quando o estudante separa

uma situação em dados disponíveis e regras do modelo.

O estudo não tratará essa mobilização como medida de um desenvolvimento amplo de pensamento computacional nem como base para afirmar melhoria em outros componentes curriculares. Essa mobilização ajuda o estudante a interpretar o conteúdo específico da sequência.

No Mundo Digital, os estudantes analisam como modelos processam representações numéricas e executam regras para produzir respostas, percebendo que uma decisão automatizada depende de elementos que podem ser analisados. A Cultura Digital aparece no exame do uso de sistemas de inteligência artificial presentes no cotidiano.

Touretzky et al. (2019) defendem que a educação em inteligência artificial para a Educação Básica deve ajudar os estudantes a compreender ideias que orientam sistemas inteligentes e seus impactos. O documento da AI4K12 sobre *machine learning* (TOURETZKY et al., 2023) situa a aprendizagem a partir de dados como uma das grandes ideias da inteligência artificial e inclui, para a faixa do Ensino Médio, a diferenciação entre aprendizagem supervisionada e não supervisionada. Essas referências não são um currículo pronto para a realidade brasileira, mas oferecem linguagem conceitual para selecionar conhecimentos que não dependam de programação avançada.

Camada e Durães (2020) identificaram possibilidades de pesquisa e aplicação para o ensino de inteligência artificial na Educação Básica a partir de uma revisão sistemática. Durães et al. (2021) relatam uma sequência didática sobre fundamentos de IA com estudantes do Ensino Médio integrado. Os estudos mostram que o tema já vem sendo trabalhado e reforçam a necessidade de considerar o tempo escolar, o repertório matemático, a mediação docente e a infraestrutura disponível.

Neste projeto, a inteligência artificial permite discutir como sistemas computacionais dependem de decisões humanas de modelagem. Compreender de onde vêm os dados e o que muda quando um parâmetro é alterado permite ao estudante questionar o resultado que recebe, em vez de apenas aceitá-lo. A questão educacional não será se o estudante consegue usar uma ferramenta generativa para terminar uma tarefa escolar. O que se buscará verificar é se, em situações delimitadas, o estudante consegue explicar como alterações em parâmetros e regras afetam previsões e classificações, de modo que a proposta permaneça vinculada ao ensino de Computação.

## 3.2 *Machine learning* introdutório no Ensino Médio

O *machine learning* ocupa lugar específico entre os conteúdos de inteligência artificial porque permite examinar como computadores identificam padrões em dados e os utilizam para produzir respostas em tarefas definidas. Ao mapearem unidades instrucionais destinadas à escola, Marques, Gresse von Wangenheim e Hauck (2020) observaram que vários materiais apresentam

apenas aspectos básicos de *machine learning* ou deixam partes do funcionamento do modelo em nível abstrato.

A proposta dispensa o detalhamento técnico de cada algoritmo. O estudante precisa compreender o suficiente para não tratar o resultado do modelo como uma resposta sem história.

Martins e Gresse von Wangenheim (2023) reúnem evidências de que estudantes iniciantes do Ensino Médio podem compreender e aplicar conceitos, algoritmos e tarefas básicas de *machine learning*. Sanusi et al. (2023), em revisão sobre a Educação Básica, também identificam experiências em diferentes níveis escolares, com presença expressiva do Ensino Médio. As pesquisas indicam lacunas na integração curricular, na formação de professores e na avaliação das intervenções. A adequação à faixa etária não depende apenas da idade dos participantes, mas do que se escolhe ensinar, de como as relações são representadas e da ajuda oferecida durante a atividade.

Esses estudos não permitem tratar o Ensino Médio como inadequado, de partida, para discutir aprendizagem a partir de dados e modelos simples. Tampouco permitem supor que qualquer atividade digital sobre inteligência artificial produzirá compreensão. As intervenções analisadas têm recursos, durações e objetivos distintos. Uma experiência conduzida em uma escola específica não se converte automaticamente em receita para outra. A literatura permite formular uma proposta viável, mas não antecipa seus resultados.

A sequência não deve começar pela expressão matemática de um algoritmo, pois isso pode afastar estudantes que ainda consolidam a leitura de gráficos e noções de proporcionalidade. A manipulação de controles e a repetição de nomes técnicos também podem ocultar o raciocínio que se pretende desenvolver. A introdução ao tema precisa partir de problemas reconhecíveis, avançar para dados e representações examináveis e aproximar, em seguida, a regra que gera uma saída. Essa progressão cria uma porta de entrada compatível com o nível de escolaridade previsto, sem diminuir o conteúdo de Computação.

O vocabulário técnico não é a única dificuldade esperada. O estudante pode precisar ler dois eixos, localizar um ponto, comparar distâncias ou reconhecer o que uma cor, uma curva ou uma regra representa. A leitura da visualização precisa ser ensinada como parte da atividade, pois observar uma mudança não significa explicar a relação que a produziu.

Há também um obstáculo matemático. Noções de função, média, probabilidade e distância nem sempre estão estabilizadas no repertório da turma. A sequência não resolverá, em oito encontros, lacunas acumuladas na escolarização matemática. Ela retomará essas noções quando forem necessárias para responder a uma pergunta concreta sobre o modelo, sem ocultar a Matemática nem antecipar uma formalização que torne a atividade inacessível.

Essa retomada não transforma o percurso em revisão extensa de Matemática antes do conteúdo de Computação. A necessidade aparece dentro de cada problema, como na comparação entre previsão e valor observado na regressão linear ou na distância entre exemplos no $k$-NN. A

mediação deverá identificar quando uma retomada curta basta e quando a dificuldade impede que a turma prossiga com a interpretação planejada. A seção 3.3 detalha como a Matemática entra nas representações.

Uma interface visual pode reduzir algumas barreiras e, ao mesmo tempo, ocultar outras. Um controle que altera o número de vizinhos torna uma mudança visível, mas não explica, por si só, por que certos pontos passam a decidir uma categoria. O recurso visual precisa ser acompanhado por mediação orientada, como se discute na seção 3.3.

A plataforma trabalha regressão linear, regressão logística, *k*-vizinhos mais próximos, árvore de decisão e *k*-means. A seleção permite discutir previsão de valores numéricos, classificação e formação de grupos sem rótulos prévios. Em cada módulo, o estudante deverá reconhecer o problema tratado, levantar uma hipótese sobre o efeito de uma alteração e explicar, após o experimento, a relação entre dados, parâmetro, gráfico e resultado.

Os modelos foram escolhidos porque mostram mecanismos distintos em representações examináveis por estudantes iniciantes. A regressão linear permite discutir tendência, previsão, resíduo e erro. A regressão logística separa probabilidade e classificação, pois uma variação no limiar altera a decisão sem modificar o valor calculado. O *k*-NN aproxima a classificação pelo confronto com exemplos semelhantes. A árvore de decisão torna visível uma sequência de condições. O *k*-means permite discutir grupos quando não existe uma categoria indicada para cada ponto.

Esse recorte reúne duas formas distintas de aprendizagem a partir de dados. Em regressão linear, regressão logística, *k*-NN e árvore de decisão, os exemplos trazem uma resposta conhecida que orienta a tarefa de prever um valor ou escolher uma categoria. No *k*-means, não há categoria fornecida previamente, e o objetivo é formar grupos a partir de uma medida de proximidade. Touretzky et al. (2023) situam essa diferenciação entre aprendizagem supervisionada e não supervisionada como uma das ideias centrais para a educação em IA. Neste projeto, ela será abordada com exemplos sintéticos e visualizações.

Os cinco módulos não devem ser assimilados com a mesma velocidade ou pelo mesmo caminho. A regressão linear pode se aproximar de conteúdos matemáticos já conhecidos, enquanto o agrupamento sem rótulos pode exigir mais tempo para que os estudantes diferenciem descobrir grupos e separar categorias previamente definidas. A retomada no encontro seguinte e a comparação coletiva no sétimo encontro evitam tratar cada modelo como episódio isolado.

O nível introdutório não exige ocultar os limites dos modelos. Uma reta resume a tendência apenas dentro do conjunto observado e pode ser afetada por pontos atípicos. Uma porcentagem representada na regressão logística não é certeza.

No *k*-NN, a decisão depende dos exemplos guardados, da escala das características e do número de vizinhos escolhido. Em árvores, regras mais detalhadas não garantem melhor comportamento em casos novos. No *k*-means, os grupos dependem do número de centroides e

de sua posição inicial. Esses limites serão tratados como questões de interpretação. O objetivo é evitar a promessa de precisão automática e uma abordagem moralizante e abstrata sobre inteligência artificial. Quando o estudante altera um dado, um limiar, uma condição ou um centroide, deve poder observar uma consequência e discutir de que regra ela decorre.

## 3.3 Representações, visualização e experimentação guiada

Ferramentas visuais permitem introduzir *machine learning* a estudantes iniciantes. Gresse von Wangenheim et al. (2021) identificaram ferramentas que favorecem a construção interativa de modelos, embora várias se concentrem na classificação de imagens e em atividades curtas. O produto proposto trabalha com dados tabulares, coletados pela turma e sintéticos, e inclui regressão, classificação e agrupamento. Essa diferença de escopo não resolve, por si só, as limitações apontadas pela literatura.

A interação só ganha sentido pedagógico quando o estudante investiga uma relação. A visualização pode tornar visível algo que permaneceria abstrato em uma explicação verbal, mas também pode dar a impressão de que observar uma mudança basta para compreendê-la. Os elementos visuais precisam ter significado explícito, e a regra do modelo deve estar acessível.

Os dados sintéticos permitem controlar o que será comparado e produzir situações em que a modificação de um elemento gera uma consequência perceptível. Não servem como previsão confiável sobre pessoas reais. Os dados coletados pela turma, nos encontros 2 e 8, mostram de onde vêm os números que serão interpretados. O cenário didático permite perguntar o que mudou, por que mudou e qual elemento do modelo participou da mudança.

Tabela, gráfico, fórmula, texto explicativo e controle interativo mobilizam múltiplas representações. Ainsworth (2006) argumenta que representações diferentes podem cumprir funções complementares durante a aprendizagem, mas exigem tarefas de interpretação e integração. A plataforma não deve apenas reunir recursos na mesma tela. Cada representação precisa responder à pergunta examinada pela turma.

A alteração na inclinação da reta, no limiar de decisão, no número de vizinhos, na condição da árvore ou na posição dos centroides deve vir acompanhada de uma questão que leve o estudante a antecipar e interpretar a mudança. Na regressão linear, a tabela mostra pares de valores, o plano cartesiano apresenta a distribuição dos pontos e a reta permite examinar tendência ou previsão. Na regressão logística, a curva e a probabilidade precisam ser lidas junto ao limiar que transforma uma estimativa em classe. No $k$-NN, o estudante relacionará a posição do ponto consultado, a distância até os exemplos e a votação dos vizinhos. Em árvores, o caminho de regras deve ser associado às condições que o produziram. Nos agrupamentos, os centroides precisam ser entendidos como posições que reorganizam os grupos, e não como marcadores

decorativos. A visualização sustenta, em cada caso, a relação entre dado, regra e saída.

O ciclo prever, experimentar, observar e explicar organiza a atividade. Antes de modificar um controle, o estudante formula uma hipótese, por escrito ou oralmente. Durante o experimento, observa o que muda no gráfico, na decisão ou na medida calculada. Depois, explica por que o resultado confirmou ou contrariou sua expectativa. O ciclo evita a tentativa e erro em que parâmetros são movimentados sem uma relação clara entre entrada e saída.

A previsão torna visível uma ideia que poderia permanecer implícita. Se um estudante afirma que aumentar o número de vizinhos não alterará uma classificação e encontra decisão diferente, o professor pode perguntar quais exemplos passaram a ser considerados e por que a votação se alterou. Quando o estudante prevê que mover um centroide não terá efeito e observa a reorganização dos pontos, a explicação pode retomar a noção de proximidade. A hipótese inicial não precisa estar correta para ter valor pedagógico.

A aplicação ocorrerá no laboratório de informática da escola, com acesso à internet. Os estudantes trabalharão em duplas, cada uma com um computador, e a restrição de acesso fora da escola não impedirá a participação, pois todas as atividades acontecerão nos encontros. Para estudantes com insegurança no manuseio do computador, os controles deverão ser legíveis e indicar o que pode ser modificado em cada momento. Para aqueles que operam a interface com facilidade, o desafio estará na explicação, não na velocidade de mover um controle. A mediação docente e o trabalho em duplas ajudam a evitar que a técnica de uso se torne obstáculo ou substitua a questão conceitual.

O controle interativo não será tratado como decoração ou recompensa após uma explicação pronta. Ele permite comparar uma consequência ao manter alguns fatores estáveis e alterar um dado ou parâmetro. A aula guiada orienta, inicialmente, uma alteração por vez, pois mudanças simultâneas dificultam atribuir uma consequência a uma causa percebida.

Depois da aula guiada, a exploração livre poderá ampliar as comparações. O professor deverá retomar a finalidade do experimento e solicitar explicações que não se limitem a descrever elementos apresentados.

As representações matemáticas serão apresentadas em camadas. Uma situação concreta introduz o problema; a tabela ou o gráfico permite localizar dados e relações; um cálculo elementar explicita uma quantidade relevante; a fórmula, quando utilizada, resume a regra discutida. A fórmula da reta, a distância entre pontos, o limiar, uma condição de árvore ou a média que atualiza um centroide devem explicar uma alteração observável, e não funcionar como requisito de memorização desarticulada.

Apresentar a Matemática em camadas não retira precisão dos conceitos. A organização em camadas define o que o estudante precisa para uma compreensão inicial e o momento em que cada noção passa a fazer sentido. Antes de calcular a distância entre dois pontos, o estudante precisa reconhecer por que a proximidade importa no $k$-NN, e antes de discutir o erro de uma

reta, precisa comparar uma previsão com um valor observado.

Quando a fórmula entra depois dessas experiências, ela deixa de ser informação isolada e passa a nomear uma relação que o estudante já pode examinar no experimento.

## 3.4 Avaliação da compreensão durante a intervenção

Avaliar o ensino de *machine learning* na Educação Básica permanece uma questão em aberto. Rauber e Gresse von Wangenheim (2023) levantaram avaliações que vão de questionários a tarefas baseadas em desempenho e destacaram a necessidade de abordagens mais abrangentes.

Gresse von Wangenheim et al. (2022) apresentam uma rubrica baseada em desempenho para conceitos e práticas de *machine learning*. A proposta mostra a necessidade de transformar expectativas de aprendizagem em critérios observáveis. Embora esteja situada em classificação de imagens, a proposta exige adaptação ao recorte desta pesquisa. Reconhecer o nome de um algoritmo não demonstra, por si só, que o estudante compreende a tarefa que ele resolve ou a relação entre dados e saída. Uma resposta numérica correta também pode resultar de tentativa, leitura superficial de um gráfico ou repetição de uma fala do professor. Os instrumentos devem solicitar justificativas breves que permitam examinar como o estudante chega a uma conclusão.

A compreensão não será medida pelo acerto em uma questão de múltipla escolha. O diagnóstico inicial e o desafio final individual oferecerão produções comparáveis. Os registros breves do professor-pesquisador ajudarão a recuperar condições de uso, dúvidas recorrentes e intervenções realizadas durante as aulas.

O diagnóstico inicial não selecionará estudantes nem medirá deficiência. Ele mostrará ideias de partida, por exemplo, quando alguém atribui uma decisão à inteligência artificial sem mencionar dados ou regras, confunde previsão com classificação ou supõe que agrupamentos já possuem categorias definidas. O desafio final retomará dimensões semelhantes em uma situação nova, com uma tabela organizada pelos próprios estudantes, sem depender da repetição literal dos exemplos explorados na plataforma.

Black e Wiliam (1998) discutem a avaliação formativa como parte do ensino, pois as informações produzidas pelos estudantes podem orientar decisões docentes. As perguntas disponíveis na plataforma terão papel de devolutiva imediata e de organização da conversa em sala. As respostas não serão coletadas digitalmente. A análise se concentrará nos instrumentos individuais e nos registros docentes previstos para a intervenção.

Durante a exploração, o professor poderá usar as previsões para identificar uma dificuldade que exija retomada, sem registrar cada fala como dado de pesquisa. Se muitas duplas interpretarem uma probabilidade de 70% como garantia de ocorrência, a aula poderá interromper a manipulação para discutir a diferença entre estimativa e certeza. Se houver confusão entre $k$-NN e $k$-means, a comparação poderá recuperar a presença ou ausência de rótulos nos exemplos.

Essas intervenções pertencem ao ensino. O registro posterior apenas contextualiza as produções individuais.

Os critérios organizam a análise em quatro dimensões: reconhecer a origem dos dados e a finalidade da tarefa, antecipar consequências de uma alteração, interpretar representações e discutir limites de uma decisão automatizada. Eles não servirão para ordenar estudantes nem produzir um índice isolado de competência. Orientarão a leitura das explicações, distinguindo respostas que apenas nomeiam elementos, descrevem mudanças ou articulam dados, procedimento e resultado.

Uma situação sobre consumo fictício de energia, por exemplo, poderá exigir que o estudante diferencie temperatura e consumo, em vez de chamar todos os valores simplesmente de dados. Outras situações poderão pedir ao estudante que antecipe o efeito de alterar um ponto ou um centroide, ajustar um limiar ou uma condição, ou modificar o número de vizinhos. A leitura de tabela, gráfico, caminho de decisão e agrupamento será examinada em relação à explicação apresentada, e não apenas pelo acerto isolado.

As respostas podem revelar níveis diferentes de elaboração sem exigir uma escala rígida de pontuação. Há diferença entre escrever que "mudou porque o programa mudou" e explicar que a alteração de limiar passou a classificar como alerta valores antes abaixo da regra estabelecida. Esses contrastes ajudam a ler as explicações, sem produzir rótulos fixos para caracterizar estudantes.

Os resultados serão apresentados em sínteses por dimensão, frequências descritivas quando ajudarem a situar o conjunto e poucos excertos anonimizados que ilustrem explicações contrastantes. As respostas individuais não serão comparadas entre alunos, e a pesquisa não pretende demonstrar uma relação causal isolada entre plataforma e aprendizagem. A discussão poderá tratar da trajetória de uma intervenção específica, das evidências produzidas em seu interior e dos limites que impedem extrapolá-las para outros contextos.

## 3.5 Síntese do referencial e posicionamento da proposta

A literatura e os documentos curriculares definem o posicionamento da proposta. O *machine learning* será tratado como conteúdo introdutório de Computação, e não como pretexto para ensinar o uso instrumental de aplicativos. A sequência seleciona ideias fundamentais, tarefas e limites observáveis, sem antecipar uma formação universitária em algoritmos. Os dados coletados pela turma e os cenários sintéticos servem ao mesmo propósito, o de permitir que o estudante saiba de onde vêm os números e o que muda quando um parâmetro é alterado. A visualização organizará uma comparação em que o estudante formula uma hipótese, observa uma consequência e explica a relação entre dado, regra e resultado.

A análise buscará evidências em produções individuais contextualizadas. Não se limitará

à medida de acertos nem prometerá um efeito causal amplo.

A literatura registra propostas, ferramentas e experiências para o ensino de IA e *machine learning* na Educação Básica, mas ainda aponta a necessidade de avaliações mais rigorosas, clareza sobre conteúdos e estratégias e atenção aos contextos de aplicação (MARTINS; GRESSE VON WANGENHEIM, 2023; RAUBER; GRESSE VON WANGENHEIM, 2023; SANUSI et al., 2023). Este projeto não pretende preencher essa lacuna sozinho nem apresentar uma plataforma inédita. A contribuição será tornar examinável a articulação entre cinco modelos, visualizações, sequência didática, instrumentos e critérios de análise, em uma turma de Ensino Médio em que o pesquisador é o professor.

A qualidade da pesquisa dependerá da coerência entre referencial, produto e método. Cada recurso do site deverá corresponder a um objetivo de aprendizagem, cada objetivo deverá aparecer em uma atividade e em um instrumento, e as conclusões deverão respeitar o que as evidências permitirem afirmar.

# 4 Produto Educacional e Sequência Didática

## 4.1 Concepção do produto educacional

O produto educacional tem duas partes: uma plataforma interativa em português brasileiro e uma sequência didática para o Ensino Médio. A plataforma funciona no navegador, trabalha com cenários sintéticos e faz os cálculos no próprio computador. Não exige cadastro nem conta de usuário, e não envia respostas nem coleta informações pessoais. Isso facilita o acesso e permite o uso com conectividade limitada, desde que o recurso esteja no computador ou na projeção da aula.

A plataforma apoia a mediação do professor no ensino de Computação. Não substitui a explicação, a conversa nem a intervenção dele.

A proposta tem cinco módulos introdutórios de *machine learning*: regressão linear, regressão logística, *k*-vizinhos mais próximos, árvore de decisão e *k*-means. Eles não formam um catálogo de comandos nem conteúdos soltos. Cada módulo mostra uma tarefa diferente com dados (prever um valor, classificar um caso, formar grupos), e a turma compara o que muda de um para outro. Todos têm lugar central na sequência, ainda que cada um mobilize uma camada matemática própria. A regressão linear traz tendência, função, previsão, resíduo e erro. A logística traz probabilidade e limiar de decisão. No *k*-NN pesa a distância entre pontos; no *k*-means, a média e a posição dos centroides; na árvore, as condições encadeadas.

A diferença de formalização não diminui nenhum módulo. Vem do repertório de estudantes iniciantes e da necessidade de tornar visível, no gráfico ou na regra, uma relação que a turma consiga discutir durante a aula.

Perguntas que voltam em todos os módulos ligam os modelos, mais do que a presença na mesma plataforma. A turma pergunta qual é o dado disponível, de onde ele vem, que saída se espera e qual alteração pode modificá-la. A resposta muda conforme o modelo. Uma reta produz uma previsão numérica; a regressão logística leva a uma probabilidade, que se compara com um limiar; o *k*-NN depende dos exemplos próximos; a árvore percorre condições; o *k*-means reorganiza pontos sem categorias dadas de antemão.

Com as mesmas perguntas em cada módulo, os estudantes comparam os modelos sem reduzi-los a uma lista de nomes, e o professor percebe se a dificuldade está em um conceito específico ou na leitura de dados e gráficos, que atravessa todos os módulos.

## 4.2 Organização pedagógica da plataforma

Cada módulo começa por uma situação-problema, pela origem dos dados e por uma pergunta sobre o que o modelo tenta aprender. Antes de mexer nos controles, o estudante prevê uma consequência. Depois altera um dado, um parâmetro ou uma regra definidos para o experimento, observa o que muda no gráfico, na classificação ou no agrupamento e explica o que aconteceu.

O ciclo prever, experimentar, observar e explicar se repete em todos os módulos e expõe o raciocínio que acompanha cada manipulação.

Mover a inclinação da reta leva o estudante a comparar a previsão com o valor observado. A troca de um limiar leva a perguntar por que a classe muda mesmo quando a porcentagem calculada continua a mesma. Com o número de vizinhos, as divisões da árvore e a posição dos centroides, a lógica é a mesma.

A sequência abre com recursos de inteligência artificial que os estudantes já usam e chega logo a um problema concreto com dados. A Matemática só entra quando a situação, o gráfico ou a decisão do modelo a exige.

Toda representação visual vem com descrição em texto, tabela ou regra, para que a compreensão não dependa só da imagem. As visualizações em 3D do protótipo complementam e não são necessárias para entender o conceito central. A interface deve preservar o controle por teclado e respeitar a preferência por redução de movimento.

## 4.3 Cenários e dados dos experimentos

Os dados das atividades serão quase todos sintéticos. Nos encontros 2 e 8, a turma organizará pequenas tabelas com dados simples, voluntários e sem nome, ou com medidas de objetos da sala. Essas tabelas servem ao ensino e ficam fora do corpus da pesquisa. Os demais cenários evitam notas, comportamentos, trajetórias e qualquer informação pessoal dos estudantes.

Os cenários são uma primeira proposta e podem mudar depois que a turma e a escola forem definidas. Na regressão linear, a ideia é relacionar temperatura e consumo fictício de energia em uma sala. Na regressão logística, a leitura de um sensor fictício permite discutir probabilidade e alerta. O $k$-NN poderá classificar objetos ou situações simuladas por duas características mensuráveis, e a árvore de decisão trabalhará uma irrigação simulada, com umidade e temperatura. No $k$-means, pontos de coleta fictícios em um mapa de bairro servem para explorar proximidade, centroides e agrupamentos sem rótulos prévios. Nenhum cenário entra só pelo apelo visual. Cada um precisa fazer a mudança de um dado ou parâmetro produzir uma consequência observável, que a turma consiga discutir com a Matemática da série.

Antes da aplicação, os exemplos serão revistos quanto à clareza da linguagem, ao tempo

que a atividade toma e à pertinência para a turma.

## 4.4 Sequência didática provisória

A sequência foi planejada, por ora, para oito encontros de cerca de cinquenta minutos. O laboratório de informática da escola, com 20 computadores e acesso à internet, já está confirmado. O número de aulas, a turma e o componente curricular dependem ainda da viabilidade do campo. O cenário preferencial é uma turma de Ensino Médio em que o pesquisador é o professor, possivelmente na disciplina Projeto Permanente por Afinidade; a proposta pode migrar para outro componente, inclusive Matemática, se a lotação e o calendário escolar exigirem.

Todo encontro mantém a mesma estrutura, mesmo quando o modelo muda. A aula abre com uma situação ou pergunta que delimita o problema. Cada estudante faz uma previsão individual breve, explora um controle ou uma representação com o colega, a turma discute o que observou e o professor fecha com uma síntese. Isso dá continuidade às aulas e deixa claro que a plataforma não é um intervalo entre explicações, mas parte do trabalho de construir e revisar hipóteses.

O primeiro encontro serve para nivelar conceitos. Antes de qualquer modelo, a turma discute aplicações cotidianas de inteligência artificial. Depois distingue os dados e a regra do modelo, até apontar o que seria entregue ao sistema e o que se espera dele. O diagnóstico inicial é individual e acontece no começo desse encontro, antes da discussão, ou na aula anterior, conforme o tempo. Registra ideias de partida, sem antecipar os nomes técnicos que aparecem depois.

Do segundo ao sexto encontro entram os módulos de regressão linear, regressão logística, $k$-NN, árvore de decisão e $k$-means. No segundo, a coleta e a organização da tabela da turma vêm antes da regressão linear. Cada aula retoma elementos das anteriores, para que nenhum modelo seja deixado de lado depois de uma única experiência.

A regressão linear e a regressão logística abrem a parte dos modelos supervisionados. Na linear, a turma reconhece uma tendência, produz uma previsão e a compara com o valor observado, o que traz o gráfico cartesiano, a reta e uma noção inicial de erro. A logística retoma a ideia de prever a partir de exemplos e leva a discussão para a probabilidade e a classificação por limiar. Como as duas aparecem em sequência, a turma compara duas saídas, um valor numérico e uma categoria, e vê que ambas dependem dos dados e das escolhas que estruturam o modelo.

O $k$-NN e a árvore de decisão são duas maneiras de chegar a uma classificação. No $k$-NN, os estudantes observam o papel da distância e do número de vizinhos na votação; na árvore, acompanham regras condicionais e os caminhos até uma decisão. Comparar os dois afasta a ideia de que exista um algoritmo melhor que os outros. Ambos usam dados e regras, cada um à sua maneira, e entregam saídas que precisam ser lidas à luz do problema e dos exemplos disponíveis.

O $k$-means traz uma mudança: os pontos não vêm com categorias dadas de antemão. A atividade volta à pergunta sobre o que se quer produzir com os dados e mostra que formar grupos por proximidade não é escolher uma classe conhecida. Os estudantes levam tempo para atualizar os centroides e observar os pontos se reorganizarem, pois a diferença entre agrupamento e classificação costuma exigir que o professor retome a linguagem dos encontros anteriores. Uma síntese breve registra o que os cinco modelos têm em comum, dados e regras que produzem uma saída, e o que muda conforme a finalidade de cada tarefa.

O sétimo encontro compara os cinco modelos. A turma analisa situações-problema e discute se a tarefa pede prever um valor, escolher uma categoria ou formar grupos, justificando com os dados disponíveis. No oitavo, as duplas organizam uma pequena tabela própria e discutem qual modelo combina com a tarefa. Depois, cada estudante faz um desafio individual de síntese. Precisa reconhecer uma situação, identificar os dados necessários, indicar um tipo de modelo compatível e explicar uma consequência possível de alterar um dado, um parâmetro ou uma regra.

O encontro comparativo não exige domínio de uma taxonomia completa de algoritmos. Recupera diferenças que podem ter ficado dispersas e prepara a transferência para o desafio final. Ao justificar por que uma situação pede previsão, classificação ou agrupamento, o estudante pensa na finalidade da tarefa antes de escolher o nome do modelo. O desafio individual segue essa lógica e verifica se relações trabalhadas em exemplos conhecidos servem a uma situação estruturalmente semelhante, com dados apresentados de outra forma.

O trabalho na plataforma será em duplas, cada uma com um computador do laboratório. As duplas favorecem a conversa sobre hipóteses. As previsões são individuais e depois discutidas em dupla; o desafio final também é individual, para que cada estudante registre a própria compreensão. Se o laboratório estiver indisponível, o professor pode projetar o experimento para a turma e manter os momentos individuais de previsão e explicação.

O detalhamento preliminar dos oito encontros reúne objetivos de aprendizagem e tempo, ações de mediação e questões formativas, e ainda as adaptações de infraestrutura e os limites didáticos de cada módulo. As previsões feitas durante a exploração têm função formativa e não formam corpus individual, porque o site não as armazena. As fontes da análise continuam sendo o diagnóstico inicial, o desafio final e os registros docentes.

A versão do site usada no campo será conferida, antes da intervenção, com os recursos previstos na sequência. Se o cenário da plataforma tiver dados diferentes dos discutidos no roteiro da aula, a diferença será corrigida ou explicada aos estudantes; o mesmo vale para os textos de apoio e as representações matemáticas.

A pesquisa não pode analisar estudantes como se tivessem passado por uma sequência diferente do recurso usado. A conferência é, por isso, condição prática para que sequência, plataforma e instrumentos tenham o mesmo objeto de aprendizagem.

## 4.5 Materiais e limites do produto

Além da plataforma, a aplicação terá um diagnóstico inicial breve, um desafio final individual e registros docentes sucintos. Não há previsão de uma cartilha extensa para cada aula, porque ela aumentaria a carga de aplicação e de correção sem ser indispensável à investigação. As perguntas do site dão devolutiva imediata durante a aprendizagem. O diagnóstico e o desafio final produzem as evidências que a pesquisa analisa.

O produto não comprova aprendizagem só por existir. Serve para que professor e estudantes discutam dados e parâmetros do modelo em sala.

A adequação didática do produto só poderá ser avaliada com a aplicação planejada, as condições reais do campo e as evidências dos estudantes; ele não será apresentado como solução pronta para qualquer escola. Antes da aplicação, uma verificação prática testará a abertura local da plataforma, a leitura dos textos em tela, o funcionamento dos controles e a projeção para a turma toda. Se algum equipamento falhar, a atividade segue com o experimento projetado e pausas para previsão e explicação individual.

A mudança de organização vai para o registro docente, porque a forma de acesso ao recurso pode alterar as interações observadas. Manter uma atividade pedagogicamente equivalente vale mais do que insistir em uma configuração técnica que a escola não consiga sustentar.

A mesma verificação confere se os enunciados se entendem sem que o estudante conheça, antes da aula, o vocabulário técnico. “Característica”, “limiar”, “vizinho” e “centroide” aparecem com explicações situadas e exemplos visíveis. Se uma formulação gerar dúvida repetida, o ajuste do texto ou da mediação entra como aperfeiçoamento do produto, não como falha do estudante. Mantém-se o desafio conceitual; saem apenas os obstáculos de linguagem ou de acesso alheios ao conteúdo.

## 4.6 Alinhamento curricular preliminar

Uma matriz explicitará o vínculo da sequência com a Computação na Educação Básica, relacionando habilidade curricular, objetivo de aprendizagem, atividade e evidência a observar. A versão preliminar toma como referências do Ensino Médio os fundamentos, as potencialidades e os limites da inteligência artificial, os modelos computacionais simples para simulação e previsão e a análise de dados com princípios de ciência de dados. Elas correspondem às habilidades EM13CO10, EM13CO11 e EM13CO12 do anexo da Resolução CNE/CEB nº 1/2022 (BRASIL, 2022).

A norma não prescreve os cinco modelos como algoritmos. Eles entram como situações didáticas para trabalhar a lógica interna de cada modelo, com seus limites. A matriz apontará ligações possíveis com a Matemática, sem tirar da Computação o lugar de objeto principal.

A escolha final das habilidades depende da série, do componente curricular, do currículo da rede e das condições confirmadas no campo.

# 5 Percurso Metodológico

## 5.1 Natureza, abordagem e estratégia da pesquisa

A pesquisa será de natureza aplicada, com abordagem predominantemente qualitativa e apoio de dados quantitativos descritivos. Não buscará medir o efeito isolado da plataforma nem estabelecer relações causais generalizáveis entre a intervenção e o desempenho de estudantes. A análise examinará indícios presentes nas produções individuais e nas situações observadas durante a aplicação da sequência didática.

A estratégia principal será uma intervenção pedagógica. Damiani et al. (2013) caracterizam esse tipo de investigação pelo planejamento e pela implementação de mudanças ou inovações pedagógicas, acompanhados da análise de seus efeitos. Essa formulação é compatível com o projeto porque os recursos da intervenção serão planejados para uma situação de ensino, aplicados no campo e examinados a partir das evidências produzidas.

A intervenção será compreendida como uma unidade formada pela sequência didática, pela plataforma, pela mediação docente e pelos instrumentos de produção de dados. Separar artificialmente esses elementos seria inadequado, pois a plataforma só adquire o sentido previsto quando está vinculada à pergunta proposta, à previsão solicitada e à discussão posterior.

Reconhecer essa unidade não autoriza atribuir qualquer mudança observada a um único componente. As produções dos estudantes serão lidas como evidências construídas em um percurso de ensino situado, no qual tempo de aula, infraestrutura, retomadas conceituais e interação entre duplas podem interferir na forma como uma explicação aparece. A posição do professor-pesquisador exigirá registro claro das condições de aplicação e prudência na interpretação dos dados.

A definição metodológica final deverá ser discutida com o orientador antes da submissão do projeto e do início da produção de dados. Essa decisão dependerá também das condições confirmadas do campo e das exigências éticas e institucionais aplicáveis.

## 5.2 Contexto e participantes

O campo previsto é uma turma de Ensino Médio de escola pública na qual o pesquisador atue como professor. A possibilidade inicial é uma turma vinculada à disciplina Projeto Permanente por Afinidade, em escola de tempo integral. Esse cenário não está garantido para o próximo ano letivo, pois a lotação docente e a composição das turmas poderão mudar.

Se necessário, a sequência poderá ser aplicada em outra turma do Ensino Médio sob do-

cência do pesquisador, inclusive em um componente de Matemática, desde que sejam preservadas as condições pedagógicas e éticas definidas para a pesquisa.

Os participantes serão estudantes iniciantes em *machine learning*. Não haverá exigência de programação prévia. A sequência pressupõe leitura de tabelas e gráficos elementares, localização de pontos em eixos cartesianos, comparação de valores e mobilização de noções iniciais de média, distância, função e probabilidade quando esses conhecimentos forem retomados durante os módulos.

O número de participantes, a série, o componente curricular, a escola e o calendário de aplicação serão informados após a confirmação do campo.

## 5.3 Etapas da intervenção

O primeiro momento corresponderá ao estudo das referências e ao aperfeiçoamento da plataforma, dos exemplos sintéticos e dos instrumentos. Em seguida, a sequência didática será preparada de acordo com a turma e as condições de infraestrutura disponíveis.

Os estudantes trabalharão em duplas, cada uma com um computador do laboratório de informática da escola, que dispõe de 20 máquinas. O trabalho em duplas cria espaço para que os estudantes comparem hipóteses diante do mesmo experimento. Durante a aula, as previsões são individuais e depois discutidas em dupla, mas as fontes analisadas na pesquisa são apenas o diagnóstico inicial, o desafio final e os registros do professor. Isso permite distinguir o que foi discutido coletivamente do que cada estudante consegue registrar e justificar. Os oito encontros correspondem a uma duração viável para esse campo e exigirão atenção às retomadas e ao ritmo efetivo da turma.

Ao final de cada encontro, o professor-pesquisador organizará uma síntese breve que recupere os elementos discutidos pela turma.

As sínteses de encerramento não terão a função de produzir uma resposta correta única para ser copiada pelos estudantes. Elas servirão para recuperar o que foi observado, explicitar relações ainda confusas e preparar a passagem para o encontro seguinte. Caso a turma confunda uma probabilidade com garantia de ocorrência, por exemplo, a retomada poderá recuperar o papel do limiar e distinguir estimativa de certeza antes de avançar para outro modelo.

O registro docente indicará que a retomada ocorreu e quais dificuldades a motivaram, sem substituir as respostas individuais como fonte de evidência da compreensão. Essa separação ajuda a preservar o vínculo entre a mediação necessária ao ensino e a análise cuidadosa do que cada participante conseguiu elaborar.

A plataforma não registrará respostas ou dados pessoais. Os registros de pesquisa serão produzidos apenas pelos instrumentos descritos a seguir.

## 5.4 Instrumentos de produção de dados

Antes da sequência, os participantes realizarão diagnóstico individual breve. O instrumento buscará identificar as ideias iniciais dos estudantes sobre como um modelo usa dados para chegar a uma previsão e sobre o efeito de alterações simples.

Ele não terá finalidade classificatória nem será tratado como prova de domínio prévio. Servirá para situar o ponto de partida das explicações dos estudantes.

Ao final da sequência, será aplicado desafio individual de síntese. Ele apresentará situação nova e solicitará que o estudante identifique os dados necessários, reconheça o tipo de tarefa, indique um modelo compatível e explique o que poderia ocorrer com uma mudança de dado, parâmetro ou regra.

Algumas questões serão equivalentes ou comparáveis às do diagnóstico. Isso permitirá examinar mudanças no uso dos conceitos sem reduzir a análise a uma contagem de acertos.

Depois de cada aula, o professor-pesquisador produzirá um registro breve, em tópicos, sobre dificuldades recorrentes, condições de uso, intervenções realizadas e situações que ajudem a interpretar as respostas dos estudantes. Não será solicitada uma cartilha extensa nem haverá intenção de coletar uma produção individual para cada módulo.

As perguntas inseridas no site terão função formativa imediata. Elas não serão utilizadas como fonte principal de dados, pois as respostas não permanecem salvas.

As versões preliminares do diagnóstico e do desafio final serão organizadas em instrumento próprio. Elas mobilizarão dimensões comparáveis: dados e finalidade da tarefa, previsão sobre uma alteração, interpretação de representação e possibilidade ou limite de uma decisão automatizada. O diagnóstico não exigirá nomes de modelos; o desafio final solicitará o emprego dos conceitos trabalhados quando pertinente. A comparação será qualitativa e descritiva, sem conversão automática das respostas em nota de ganho.

A comparabilidade entre os instrumentos não dependerá de repetir a mesma pergunta ou de apresentar novamente o mesmo cenário. Repetições literais podem favorecer a lembrança da atividade anterior sem revelar se a relação conceitual foi mobilizada em outra situação.

O diagnóstico poderá perguntar, por exemplo, que informações seriam necessárias para uma recomendação ou classificação simples. O desafio final apresentará um conjunto de dados diferente e solicitará que o estudante justifique a escolha de uma tarefa, de um modelo ou de uma alteração possível. A dimensão observada permanece a mesma, mas a situação exige que a resposta seja reconstruída. Quando houver item equivalente, sua formulação deverá manter o foco na explicação, não apenas no reconhecimento de uma palavra trabalhada durante a sequência.

Os instrumentos também precisarão ser compatíveis com o tempo escolar disponível e com o fato de que os participantes serão estudantes do Ensino Médio em uma atividade inserida no cotidiano da turma. Não se pretende aplicar teste extenso que interrompa a sequência ou

transforme a intervenção em rotina de avaliação formal.

Perguntas abertas curtas, acompanhadas de gráfico, tabela ou situação-problema, podem oferecer indícios mais úteis que grande quantidade de itens objetivos, desde que o enunciado deixe claro o que se pede. Antes da aplicação, o professor-pesquisador verificará se cada questão está ligada a um objetivo de aprendizagem e a uma atividade efetivamente realizada.

Caso algum conceito não tenha sido abordado nas condições previstas, ele não deverá ser tratado como ausência de compreensão no desafio final. Essa precaução mantém os instrumentos vinculados ao percurso de ensino e protege a análise contra interpretações que ultrapassem as evidências disponíveis.

## 5.5 Procedimentos de análise

As respostas ao diagnóstico e ao desafio final serão organizadas por códigos, sem identificação nominal dos participantes. A análise será orientada por critérios construídos a partir dos objetivos de aprendizagem da sequência: diferenciar dados, características e finalidade do modelo; antecipar consequência de alteração simples em dado, parâmetro ou regra; interpretar uma representação; e justificar o resultado observado, relacionando entrada, procedimento computacional e saída com apoio no conceito ou na matemática trabalhada.

A primeira etapa consistirá na leitura integral das respostas e na organização de uma matriz por participante e dimensão de análise. Em cada dimensão, será registrada a presença, a ausência ou a forma de manifestação de uma explicação, sem apresentar essa marcação como nota individual.

Uma resposta poderá apenas indicar que “a classificação mudou”, enquanto outra relacionará a mudança ao limiar escolhido ou à proximidade entre exemplos. A diferença entre esses modos de explicar será mais informativa que uma oposição simples entre certo e errado.

Em seguida, as respostas do diagnóstico e do desafio final serão colocadas em relação, procurando continuidades, deslocamentos e dificuldades persistentes. A análise considerará, por exemplo, se o estudante passa a distinguir uma tarefa de previsão de uma tarefa de classificação, se identifica dados compatíveis com um problema e se consegue prever uma consequência antes de observá-la na tela.

Quando houver condições para isso, frequências descritivas poderão indicar quantas produções apresentam determinada característica. Elas servirão para situar o conjunto, não para sustentar inferências estatísticas ou generalizações sobre outras turmas.

Os registros não serão apresentados integralmente na dissertação. O texto final deverá reunir sínteses das respostas, frequências descritivas quando contribuírem para a leitura do conjunto e poucos excertos anonimizados que ilustrem modos distintos de explicação. Os registros docentes contextualizarão os resultados quando uma dificuldade recorrente, uma retomada

matemática ou uma condição de infraestrutura ajudar a compreender as produções escritas.

A interpretação aproximará o que o estudante escreveu das condições em que a atividade ocorreu, mas não usará registros do professor para completar ou atribuir ao participante compreensão que não esteja evidenciada em sua produção individual. Essa separação é inegociável para que a análise permaneça prudente e compatível com as fontes produzidas.

## 5.6 Aspectos éticos

A produção de dados somente poderá começar após a confirmação das exigências institucionais e éticas aplicáveis ao projeto. A Resolução CNS nº 510/2016 dispõe sobre pesquisas em Ciências Humanas e Sociais que utilizam dados obtidos diretamente de participantes ou informações identificáveis, enquanto a Resolução CNS nº 466/2012 estabelece diretrizes gerais para pesquisas envolvendo seres humanos (BRASIL, 2016; BRASIL, 2012).

Como a intervenção poderá envolver adolescentes, os procedimentos éticos deverão ser definidos conforme a orientação institucional e a tramitação exigida antes da aplicação.

As respostas serão anonimizadas por códigos, e documentos com informações de identificação, quando necessários, serão mantidos separadamente dos instrumentos de análise. Dados brutos não serão inseridos no código da plataforma nem publicados em repositório aberto. A participação será voluntária. Estudantes que não participarem da produção de dados deverão ter acesso a atividade pedagógica equivalente, sem prejuízo da experiência escolar.

# 6 Contribuições Esperadas e Limites da Proposta

## 6.1 Contribuições esperadas

Espera-se produzir uma proposta de ensino introdutório de *machine learning* situada no campo da Computação na Educação Básica. A contribuição articula plataforma local, sequência didática de oito encontros, instrumentos individuais de diagnóstico e síntese, critérios de análise e orientações de mediação docente. Esse conjunto poderá tornar explícitas relações entre os dados e as saídas de um modelo, e também os limites de sistemas de inteligência artificial.

No plano pedagógico, a proposta deverá oferecer percurso para estudantes iniciantes que não depende de programação prévia nem de formalização matemática avançada. A expectativa é criar condições para formular hipóteses, testar uma alteração e explicar a consequência observada, relacionando representações gráficas e tabelas. O interesse da pesquisa não é afirmar domínio técnico profundo dos modelos, mas identificar compreensões conceituais situadas ao longo da intervenção.

No plano curricular, a matriz construída para o projeto permitirá explicitar a relação entre os objetivos de aprendizagem, as atividades e as habilidades de Computação do Ensino Médio relacionadas a fundamentos de inteligência artificial, exploração de modelos simples e análise de dados. Essa articulação procura contribuir para discussões sobre a implementação da Computação na Educação Básica sem alegar que a BNCC prescreve algoritmos específicos ou uma forma única de organização curricular.

No plano profissional, a investigação poderá sistematizar uma experiência de docência adaptável a outros contextos de Ensino Médio, desde que sejam respeitadas condições de infraestrutura, mediação, conhecimento prévio e adequação curricular de cada escola. Plataforma e materiais não serão apresentados como solução pronta ou universal. Poderão, contudo, oferecer subsídios para professores interessados em tratar inteligência artificial e dados de forma menos centrada no uso passivo de ferramentas prontas.

O produto também deverá tornar visível o percurso de planejamento que sustenta sua utilização. Não bastará disponibilizar telas, gráficos e controles. A sequência, os cenários, as perguntas de previsão e os critérios de análise precisarão indicar que compreensão se pretende favorecer em cada atividade e que tipo de explicação poderá ser observado.

Essa documentação poderá ajudar outros professores a adaptar a proposta sem perder de vista a relação entre conteúdo de Computação, Matemática mobilizada e mediação necessária em sala de aula.

A finalidade não será padronizar aulas para contextos distintos, mas oferecer uma referência suficientemente explícita para que adaptações futuras sejam justificadas e não reduzam a proposta a uma demonstração de ferramentas.

## 6.2 Limites e riscos reconhecidos

O número de encontros e a duração prevista da intervenção limitam a profundidade com que cada modelo poderá ser abordado. Trabalhar cinco modelos introdutórios em oito aulas exige retomadas e comparações constantes, mas não permite supor que uma única exploração resulte em aprendizagem consolidada. O projeto deverá priorizar conceitos e relações fundamentais, deixando de fora formalizações e procedimentos técnicos que ultrapassem o nível introdutório definido.

Diferenças no repertório matemático, na experiência de uso de computador e no acesso a equipamentos podem afetar a participação dos estudantes. A sequência prevê estratégias de acesso e mediação. Essas medidas não eliminam desigualdades de acesso ou de experiência. Os registros docentes ajudarão a interpretar como tais condições interferem nas produções individuais, evitando atribuir ao modelo ou à plataforma explicação exclusiva para as respostas observadas.

O estudo será realizado em uma turma sob docência do pesquisador, ainda a ser definida. Por esse motivo, suas evidências estarão vinculadas a um contexto específico, à mediação realizada, aos dados sintéticos selecionados e às condições materiais daquele campo. Não se pretende generalizar resultados para todas as escolas públicas ou medir um efeito causal isolado da plataforma.

Da mesma forma, a comparação entre diagnóstico e desafio final permitirá examinar transformações nas explicações, sem que isso estabeleça, por si só, uma medida universal de aprendizagem.

Há limites próprios dos modelos e das representações adotadas. Os conjuntos de dados serão simplificados para tornar relações visíveis, e os resultados produzidos pela interface não deverão ser confundidos com previsões confiáveis sobre pessoas ou situações reais. As vistas tridimensionais representarão métricas calculadas, não atributos adicionais dos dados.

Os elementos didáticos deverão ser revistos antes da aplicação, evitando reforçar a ideia de que sistemas de inteligência artificial são neutros, autônomos ou infalíveis.

# 7 Cronograma Provisório

O cronograma será ajustado após a confirmação da turma, da lotação docente, do componente curricular, do calendário escolar e das exigências institucionais e éticas. A Tabela 1 apresenta a ordem de trabalho prevista; ela não substitui o calendário acadêmico oficial nem as condições que ainda dependem da definição do campo.

Tabela 1 – Etapas e atividades do cronograma provisório da pesquisa

| **Etapa** | **Atividades principais** | **Condição para conclusão** |
|---|---|---|
| 1. Consolidação do projeto | Revisar problema, objetivos, referencial, matriz curricular, sequência e instrumentos. | Versão de qualificação coerente e submetida à apreciação do orientador. |
| 2. Aperfeiçoamento do produto | Padronizar cenários sintéticos, adequar textos e controles do site à sequência, criar síntese comparativa e realizar verificações de acessibilidade e projeção. | Protótipo compatível com a aplicação planejada. |
| 3. Preparação do campo | Confirmar turma, escola, componente curricular, infraestrutura, calendário e autorizações aplicáveis. | Campo definido e condições pedagógicas e éticas confirmadas. |
| 4. Revisão dos instrumentos | Ajustar diagnóstico, desafio final, rubrica e registro docente ao perfil da turma. | Instrumentos revisados e prontos para uso. |
| 5. Aplicação da intervenção | Realizar os oito encontros, produzir registros docentes e aplicar diagnóstico e desafio final. | Produções organizadas por códigos, sem identificação nominal no corpus de análise. |
| 6. Organização e análise | Anonimizar, organizar e analisar respostas e registros; elaborar sínteses, frequências descritivas e excertos. | Categorias analíticas e resultados interpretados. |
| 7. Redação da dissertação e do produto | Redigir resultados, discussão, considerações finais e versão final do produto educacional. | Versão submetida às revisões do orientador. |
| 8. Revisão e entrega | Revisar normalização, ética, acessibilidade, anexos e exigências de depósito. | Trabalho e produto preparados para a etapa institucional correspondente. |

Fonte: Elaborado pelo autor (2026).

# Referências

AINSWORTH, S. Deft: A conceptual framework for considering learning with multiple representations. *Learning and Instruction*, v. 16, n. 3, p. 183–198, 2006. Disponível em: <https://doi.org/10.1016/j.learninstruc.2006.03.001>. Citado 2 vezes nas páginas 3 e 10.

BLACK, P.; WILIAM, D. Assessment and classroom learning. *Assessment in Education: Principles, Policy & Practice*, v. 5, n. 1, p. 7–74, 1998. Disponível em: <https://doi.org/10.1080/0969595980050102>. Citado 2 vezes nas páginas 3 e 12.

BRASIL. *Resolução nº 466, de 12 de dezembro de 2012: aprova diretrizes e normas regulamentadoras de pesquisas envolvendo seres humanos*. Brasília, DF, 2012. Disponível em: <https://www.gov.br/conselho-nacional-de-saude/pt-br/atos-normativos/resolucoes/2012/resolucao-no-466.pdf/view>. Citado na página 25.

BRASIL. *Resolução nº 510, de 7 de abril de 2016: dispõe sobre as normas aplicáveis a pesquisas em Ciências Humanas e Sociais*. Brasília, DF, 2016. Disponível em: <https://www.gov.br/conselho-nacional-de-saude/pt-br/atos-normativos/resolucoes/2016/resolucao-no-510.pdf/view>. Citado na página 25.

BRASIL. *Resolução CNE/CEB nº 1, de 4 de outubro de 2022: normas sobre Computação na Educação Básica, complemento à Base Nacional Comum Curricular (BNCC)*. Brasília, DF, 2022. Disponível em: <https://portal.mec.gov.br/docman/outubro-2022-pdf/241671-rceb001-22/file>. Citado 3 vezes nas páginas 1, 6 e 19.

BRASIL. *Inteligência artificial na Educação Básica: documento orientador sobre caminhos curriculares e práticas éticas de uso de IA nas escolas*. Brasília, DF: Ministério da Educação, 2026. 88 p. Disponível em: <https://www.gov.br/mec/pt-br/escolas-conectadas/arquivos/ia-basica.pdf>. Citado na página 1.

CAMADA, M. Y.; DURãES, G. M. Ensino da inteligência artificial na educação básica: um novo horizonte para as pesquisas brasileiras. In: *Anais do XXXI Simpósio Brasileiro de Informática na Educação (SBIE 2020)*. [s.n.], 2020. p. 1553–1562. Disponível em: <https://doi.org/10.5753/cbie.sbie.2020.1553>. Citado na página 7.

DAMIANI, M. F. et al. Discutindo pesquisas do tipo intervenção pedagógica. *Cadernos de Educação*, n. 45, p. 57–67, 2013. Disponível em: <https://doi.org/10.15210/caduc.v0i45.3822>. Citado na página 21.

DURãES, G. M. et al. Ensino de fundamentos da inteligência artificial no ensino médio integrado sob a perspectiva educacional e tecnológica de paulo freire. *Trilhas: Revista de Extensão do IF Baiano*, v. 1, n. 2, 2021. Disponível em: <https://periodicos.ifbaiano.edu.br/index.php/trilhas/article/view/87>. Citado na página 7.

Gresse von Wangenheim, C. et al. A proposal for performance-based assessment of the learning of machine learning concepts and practices in k-12. *Informatics in Education*, v. 21, n. 3, p. 479–500, 2022. Disponível em: <https://doi.org/10.15388/infedu.2022.18>. Citado na página 12.

Gresse von Wangenheim, C. et al. Visual tools for teaching machine learning in k-12: A ten-year systematic mapping. *Education and Information Technologies*, v. 26, n. 5, p. 5733–5778, 2021. Disponível em: <https://doi.org/10.1007/s10639-021-10570-8>. Citado na página 10.

MARQUES, L. S.; Gresse von Wangenheim, C.; HAUCK, J. C. R. Teaching machine learning in school: A systematic mapping of the state of the art. *Informatics in Education*, v. 19, n. 2, p. 283–321, 2020. Disponível em: <https://doi.org/10.15388/infedu.2020.14>. Citado 2 vezes nas páginas 2 e 7.

MARTINS, R. M.; Gresse von Wangenheim, C. Findings on teaching machine learning in high school: A ten-year systematic literature review. *Informatics in Education*, v. 22, n. 3, p. 421–440, 2023. Disponível em: <https://doi.org/10.15388/infedu.2023.18>. Citado 4 vezes nas páginas 2, 3, 8 e 14.

RAUBER, M. F.; Gresse von Wangenheim, C. Assessing the learning of machine learning in k-12: A ten-year systematic mapping. *Informatics in Education*, v. 22, n. 2, p. 295–328, 2023. Disponível em: <https://doi.org/10.15388/infedu.2023.11>. Citado 2 vezes nas páginas 12 e 14.

SANUSI, I. T. et al. A systematic review of teaching and learning machine learning in k-12 education. *Education and Information Technologies*, v. 28, p. 5967–5997, 2023. Disponível em: <https://doi.org/10.1007/s10639-022-11416-7>. Citado 2 vezes nas páginas 8 e 14.

SOCIEDADE BRASILEIRA DE COMPUTAÇÃO. *Diretrizes para ensino de Computação na Educação Básica*. Brasília, DF, 2018. Disponível em: <https://www.sbc.org.br/wp-content/uploads/2024/07/DiretrizesSBC-ComputacaoNaEducacaoBasica.pdf>. Citado na página 6.

TOURETZKY, D. S. et al. Machine learning and the five big ideas in ai. *International Journal of Artificial Intelligence in Education*, v. 33, p. 233–266, 2023. Disponível em: <https://doi.org/10.1007/s40593-022-00314-1>. Citado 2 vezes nas páginas 7 e 9.

TOURETZKY, D. S. et al. Envisioning ai for k-12: What should every child know about ai? In: *Proceedings of the AAAI Conference on Artificial Intelligence*. [s.n.], 2019. v. 33, n. 1, p. 9795–9799. Disponível em: <https://doi.org/10.1609/aaai.v33i01.33019795>. Citado 2 vezes nas páginas 1 e 7.

VALENTE, J. A. Uso da internet em sala de aula. *Educar em Revista*, n. 19, p. 131–146, 2002. Disponível em: <https://revistas.ufpr.br/educar/article/view/2086>. Citado na página 6.

WING, J. M. Computational thinking. *Communications of the ACM*, v. 49, n. 3, p. 33–35, 2006. Disponível em: <https://doi.org/10.1145/1118178.1118215>. Citado na página 6.